CIMAT

Centro de Investigación en Matemáticas, A.C.

La Voz del Turista: Flujo de Trabajo Basado en Modelos de Lenguaje para la Mejora de la Ventaja Competitiva en Pueblos Mágicos

T E S I S

Que para obtener el grado de

Maestro en Cómputo Estadístico

Presenta

Gustavo Hernández Angeles

Director de Tesis:

Dr. Norberto Alejandro Hernández Leandro

Autorización de la versión final

Monterrey, Nuevo León, Xxxx de 2026

To my family.

Acknowledgements

To my parents Octavio and Abigail, who have provided me with immense and unconditional support. They are my inspiration and strength.

To my brothers, Arael and Javier, for their constant support and for being role models.

To my friends, for making this journey more bearable with laughter and constant support.

To Yazmin, for the great support, patience, and continuous joys.

Abstract

The use of LLMs has revolutionized the way organizations can analyze and leverage large volumes of unstructured data. In particular, tourist destinations face the challenge of extracting valuable information from tourists' opinions and comments to improve their competitive advantage. Traditionally, opinion analysis requires significant manual effort or NLP techniques that may not fully capture the context and nuances of human language.

In this thesis, we present a workflow based on LLMs to analyze tourists' opinions in Mexico's *Pueblos Mágicos*, aiming to identify insights in their hotel and restaurant markets, as well as natural and historical tourist resources, promoting continuous improvement of competitive advantage in Pueblos Mágicos. We propose a Map-Reduce workflow that integrates RAG for review retrieval using Sentence Transformer models (also known as bi-encoders) that capture the semantics of opinions. Subsequently, LLMs are employed for analyzing and synthesizing the retrieved information, generating executive reports that highlight key areas for improvement and strategic opportunities.

Keywords: Large Language Models, Competitive Advantage, Pueblos Mágicos, Tourism, Opinion Analysis, Retrieval-Augmented Generation, Sentence Transformers.

Contents

Acknowledgements **iii**

Abstract **v**

List of Figures **ix**

1 Introducción **1**
1.1 Related Work 1
1.2 Hipótesis de trabajo 1
1.3 Objetivos 1
1.4 Contribución 1
1.5 Organización de la tesis 1

2 Marco teórico **3**

3 Análisis Exploratorio **5**
3.1 Bases de datos 5

4 Modelación espacio-temporal **7**
4.1 Modelos espaciales 7

5 Conclusiones y trabajo futuro **9**

References **11**

A Anexo **13**

List of Figures

3.1 Selección de 7 estados de la República Mexicana para la modelación. Este mapa fue construido con el uso de `ggmap` (Kahle & Wickham, 2013) y requirió la activación de los servicios de Google Maps. 5

4.1 Gráfica Acíclica Dirigida de la representación jerárquica del modelo Poisson-Gamma. 8

Chapter 1

Introducción

El aumento exponencial de información generada por los usuarios en plataformas digitales ha transformado la manera en que las organizaciones comprenden y responden a las necesidades y preferencias de sus clientes.

1.1 Related Work

1.2 Hipótesis de trabajo

1.3 Objetivos

1.4 Contribución

En literatura existe una basta colección de trabajos que abordan el problema...

1.5 Organización de la tesis

Chapter 2

Marco teórico

Como se mencionó en el capítulo anterior, ante el problema que representa el aumento de violencia en el país, han surgido diversas investigaciones para tratar de explicar cómo ha sido la dinámica del crimen organizado, cuales son las posibles repercusiones que tiene, las desventajas de las medidas tomadas para reducirla así como también cuáles serían las nuevas alternativas para intentar combatirla.

Para comprender la motivación, objetivos y desarrollo de esta tesis, en este capítulo presentaremos los antecedentes a la "Guerra contra las drogas" en México, la política de drogas empleada por el gobierno mexicano, el fenómeno de migración de américa central y del sur hacia nuestro país y finalmente una breve reseña sobre los cultivos de amapola y marihuana en el territorio mexicano.

Chapter 3

Análisis Exploratorio

3.1 Bases de datos

Figure 3.1: Selección de 7 estados de la República Mexicana para la modelación. Este mapa fue construido con el uso de `ggmap` (Kahle & Wickham, 2013) y requirió la activación de los servicios de Google Maps.

Chapter 4

Modelación espacio-temporal

4.1 Modelos espaciales

Modelo Poisson-Gamma

Para este tipo de modelos es posible utilizar representaciones gráficas que reflejen la estructura de dependencias en la jerarquía. Esta representación es conocida como *Grafo Acíclico Dirigido* (DAG). Las aristas conectan los niveles de la jerarquía y los parámetros son los vértices al final de las aristas (flechas). Es importante establecer un límite en la jerarquía ya que no es posible asumir una jerarquía de parámetros infinita. Usualmente el punto de corte se elige donde la variación de los hiperparámetros ya no afecta al nivel más bajo del modelo (primer nivel). En este punto los parámetros se asumen como valores fijos. Por ejemplo en el modelo *Poisson-Gamma* si se fijan α y β entonces la distribución a priori *Gamma* será fija y los datos no nos darán información acerca de la distribución en lo absoluto. Sin embargo podemos permitir un nivel mayor de variación asignando hiperdistribuciones a priori para α y β, fijando los valores de ν y ρ sin afectar radicalmente el nivel más bajo de variación. La Figure 4.1 muestra el DAG para el modelo *Poisson-Gamma* de dos niveles (Lawson, 2013).

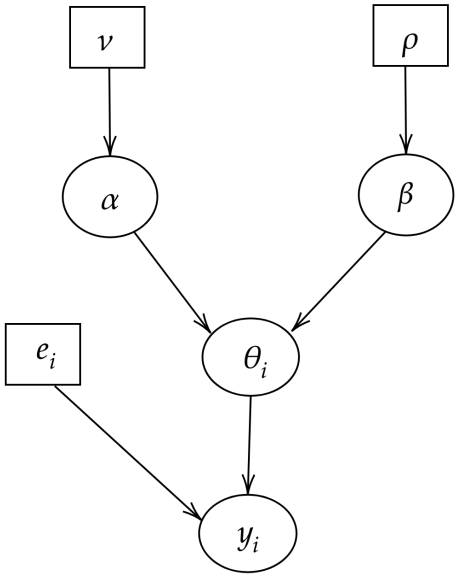

Figure 4.1: Gráfica Acíclica Dirigida de la representación jerárquica del modelo Poisson-Gamma.

Chapter 5

Conclusiones y trabajo futuro

References

Kahle, D., & Wickham, H. (2013). ggmap: Spatial visualization with ggplot2. *The R Journal*, *5*(1), 144–161. Retrieved from https://journal.r-project.org/archive/2013-1/kahle-wickham.pdf

Lawson, A. (2013). *Bayesian disease mapping: Hierarchical modeling in spatial epidemiology, second edition*. Taylor & Francis. Retrieved from https://books.google.com.mx/books?id=g7RJEZb1umwC

Appendix A

Anexo